Estudo Experimental de Desempenho de Protocolos Web

HTTP/1.1, HTTP/2 e HTTP/3 em Ambiente Emulado

Kleber Moura de Jesus
Universidade Federal do Piauí – CSHNB
Redes II

20 de outubro de 2026

Vídeo de apresentação (15 minutos): link não listado do YouTube a inserir após a gravação.

Resumo

Este trabalho compara HTTP/1.1 sobre TCP, HTTP/2 protegido por TLS 1.3 sobre TCP e HTTP/3 sobre QUIC em dois cenários de rede emulados. São avaliadas a transferência de um objeto de 50 MB e a transferência concorrente de 100 objetos de 10 KB. O cliente registra o tempo até o primeiro byte do corpo (TTFB), tempos de resposta, duração total da carga, requisições por segundo (RPS), percentis e bytes recebidos. Foram executadas duas rodadas completas de T01–T12, com cinco repetições por teste. Os resultados mostram que o desempenho depende da carga e do cenário: HTTP/3 teve vantagem na transferência grande sob WAN na segunda rodada, mas não foi o mais rápido em todos os testes. A análise considera a multiplexação, o bloqueio de início de linha, a variabilidade entre repetições e as limitações das implementações utilizadas.

Palavras-chave: HTTP/1.1; HTTP/2; HTTP/3; QUIC; TCP; desempenho; `tc netem`.

1 Introdução

HTTP/1.1, HTTP/2 e HTTP/3 oferecem semânticas de aplicação semelhantes, mas diferem no transporte, no estabelecimento seguro de conexão e na multiplexação. Essas decisões podem alterar a latência de início, a vazão e a cauda da distribuição de latência, sobretudo quando há RTT alto e perda de pacotes. O objetivo deste estudo é medir essas diferenças de maneira reprodutível, mantendo fixos os perfis de conteúdo e a emulação do caminho.

O experimento não presume que um protocolo será sempre superior. A interpretação distingue custo de handshake, transferência de um objeto grande, concorrência de objetos pequenos, implementação concreta dos servidores e variação entre repetições.

2 Fundamentação teórica

2.1 HTTP/1.1 e HTTP/2 sobre TCP

HTTP/1.1 utiliza TCP e, neste ensaio, não utiliza TLS. Uma conexão TCP nova exige o estabelecimento do transporte antes da troca de dados da aplicação. O ensaio de carga A abre uma conexão nova por amostra para que a latência inicial inclua esse custo. Para a carga B, o cliente mantém uma conexão persistente; HTTP/1.1 não multiplexa respostas independentes no mesmo canal como HTTP/2, e o limite de uma conexão no pool deixa visível a serialização das respostas.

HTTP/2 mantém a semântica de HTTP sobre TLS 1.3/TCP e multiplexa streams por quadros na mesma conexão. Isso elimina o bloqueio de aplicação próprio da sequência de respostas do HTTP/1.1, mas não elimina a entrega ordenada do TCP. Uma perda de segmento pode atrasar a entrega dos bytes subsequentes da conexão, inclusive bytes pertencentes a outros streams.

2.2 TCP CUBIC – Tanenbaum §6.5.11

TCP CUBIC ajusta a janela de congestionamento usando uma função cúbica do tempo desde o último evento de congestionamento. Após detectar perda, o algoritmo reduz a janela e tenta retomar o crescimento de forma mais rápida perto do valor de janela anterior, mantendo uma curva de crescimento mais suave quando se afasta daquele ponto. Em uma WAN emulada com perdas estocásticas, perdas repetidas podem provocar novas reduções antes de a janela recuperar o nível necessário para preencher o caminho. O RTT também aumenta o tempo necessário para receber confirmações e retransmitir dados. A consequência esperada é a redução da vazão TCP útil em T04 e T05, não porque a cifragem TLS altere o algoritmo CUBIC, mas porque ambos dependem de TCP e enfrentam a mesma perda do caminho. A magnitude dessa diferença é resultado experimental.

Essa interpretação depende da implementação e do sistema operacional do servidor que envia os dados. O comportamento de controle de congestionamento não pode ser atribuído apenas ao cliente HTTP nem inferido da porcentagem nominal de perda; deve ser tratado como uma explicação compatível com o mecanismo TCP observado.

2.3 QUIC e BBR – Tanenbaum §§6.6.1–6.6.2

QUIC integra TLS 1.3 ao estabelecimento de transporte sobre UDP e oferece streams independentes. Diferentemente da entrega ordenada global do TCP, a perda de dados de um stream QUIC não exige que dados já recebidos de outros streams aguardem a retransmissão daquele stream. Essa propriedade reduz o bloqueio de início de linha (HoL blocking) entre streams de HTTP/3, mas não elimina bloqueios dentro do mesmo stream, perdas, retransmissões ou contenção de congestionamento compartilhado pela conexão.

O BBR estima a largura de banda do gargalo e o RTT mínimo para controlar o ritmo de envio, em vez de usar cada perda isolada como único sinal de congestionamento. Esse princípio pode ajudar a explicar resiliência em enlaces com perdas não necessariamente causadas por congestionamento. Contudo, QUIC não implica que BBR esteja ativo: o algoritmo selecionado depende da implementação do servidor QUIC. Como a configuração e a versão usadas neste experimento não confirmaram BBR, não se atribuem a esse

algoritmo os resultados de T06, T09 ou T12.

3 Metodologia

3.1 Ambiente e controle experimental

O ambiente é composto por Nginx servindo HTTP/1.1 e HTTP/2 com TLS 1.3, Caddy servindo HTTP/3/QUIC e um cliente Python assíncrono. Os quatro contêineres pertencem à rede bridge `172.20.0.0/16`. O cliente também está na bridge para que o atraso configurado em sua saída e na saída dos servidores forme o caminho de ida e volta. Na LAN aplica-se 0,5 ms em cada sentido e nenhuma perda. Na WAN aplicam-se 25 ms de atraso em cada sentido e 2% de perda somente na saída dos servidores, evitando somar duas taxas de perda de 2%.

O runner gera um certificado autoassinado de laboratório com SAN para os nomes dos serviços, gera objetos com bytes pseudoaleatórios para reduzir efeitos de compressibilidade, constrói e inicia os contêineres, executa a matriz, salva os dados, gera os gráficos e remove os contêineres e as disciplinas `tc`. O certificado é confiável pelo cliente via arquivo de CA; a validação do certificado não é desativada.

Na carga A, cada amostra cria e fecha uma sessão de cliente/conexão antes da próxima medição. Assim, o TTFB inclui o estabelecimento de TCP/TLS ou QUIC. Na carga B, cada repetição mantém uma única conexão de transporte por protocolo, e os 100 pedidos são submetidos concorrentemente por essa conexão. HTTP/1.1 é limitado a uma conexão e serializa as respostas; HTTP/2 e HTTP/3 podem multiplexar streams. O cliente solicita `no-cache` e `no-store`, não implementa cache, e os servidores enviam `Cache-Control: no-store`.

Cada teste tem cinco repetições. Os gráficos exibem média e desvio-padrão entre repetições. Média, mediana e desvio-padrão de TTFB são calculados sobre as cinco médias por amostra; p50 e p99 de TTFB e duração individual são calculados sobre os registros de requisições. Para Carga B, há 500 requisições individuais por teste (100 em cada uma de cinco repetições). Para Carga A, há somente cinco observações individuais por teste, portanto seus percentis empíricos são pouco precisos. RPS e tempo total da carga são estatísticas das cinco amostras agregadas.

3.2 Matriz experimental

Tabela 1: Matriz dos doze testes realizados.

Teste	Carga	Protocolo	Rede	Foco analítico
T01	1 × 50 MB	HTTP/1.1	LAN	Vazão TCP sem perda
T02	1 × 50 MB	HTTP/2 + TLS 1.3	LAN	TLS e TCP cifrado
T03	1 × 50 MB	HTTP/3	LAN	QUIC sem perda
T04	1 × 50 MB	HTTP/1.1	WAN	RTT e perda em TCP
T05	1 × 50 MB	HTTP/2 + TLS 1.3	WAN	TCP/TLS sob perda
T06	1 × 50 MB	HTTP/3	WAN	QUIC sob perda
T07	100 × 10 KB	HTTP/1.1	LAN	Serialização de respostas
T08	100 × 10 KB	HTTP/2 + TLS 1.3	LAN	Multiplexação HTTP/2
T09	100 × 10 KB	HTTP/3	LAN	Streams QUIC
T10	100 × 10 KB	HTTP/1.1	WAN	RTT/perda e serialização
T11	100 × 10 KB	HTTP/2 + TLS 1.3	WAN	Perda TCP e multiplexação
T12	100 × 10 KB	HTTP/3	WAN	Streams QUIC sob perda

3.3 Métricas

O TTFB registrado é o intervalo, em microssegundos, desde o início do pedido até o primeiro byte do corpo da resposta. Ele inclui estabelecimento de conexão nos testes frios. O tempo de resposta individual mede até o último byte do objeto; o tempo total da carga mede a janela completa da amostra. RPS é o total de respostas bem-sucedidas dividido por essa janela. Os percentis p50 e p99 de latência são calculados sobre tempos individuais de resposta.

3.4 Registro das execuções

Foram realizadas duas execuções completas em 20 de outubro de 2026. Cada rodada contém cinco repetições para cada um dos doze testes (60 amostras agregadas por rodada), além dos registros brutos por requisição.

Tabela 2: Execuções preservadas e respectivos artefatos.

Rodada	Identificador	Cobertura	Artefatos
1	`20261020T194130Z-578`	T01–T12, 5 repetições/teste	JSON; CSV; resumo
2	`20261020T205948Z-881`	T01–T12, 5 repetições/teste	JSON; CSV; resumo

Os diretórios e arquivos de cada rodada foram preservados separadamente. As rodadas são reportadas individualmente, sem combinar amostras nem selecionar apenas a rodada mais favorável. As diferenças entre rodadas são apresentadas como variação observada entre execuções, não como estimativa estatística independente de dez repetições.

4 Resultados

Os gráficos da segunda rodada apresentam média e desvio-padrão entre as cinco repetições. A Tabela 3 compara métricas agregadas selecionadas; os valores após ± são desvios-padrão entre repetições, não intervalos de confiança.

Tabela 3: Comparação selecionada entre as duas rodadas.

Teste e métrica	Rodada 1	Rodada 2
T03 – tempo total da carga A (s)	$4{,}207 \pm 1{,}026$	$3{,}824 \pm 0{,}214$
T06 – tempo total da carga A WAN (s)	$114{,}292 \pm 7{,}292$	$110{,}153 \pm 4{,}624$
T08 – RPS da carga B LAN	$161{,}87 \pm 28{,}87$	$248{,}05 \pm 24{,}13$
T09 – RPS da carga B LAN	$192{,}66 \pm 29{,}20$	$225{,}10 \pm 6{,}41$
T12 – RPS da carga B WAN	$53{,}99 \pm 34{,}11$	$94{,}05 \pm 37{,}86$

Na segunda rodada, HTTP/3 apresentou menor tempo médio de carga que HTTP/1.1 e HTTP/2 em T06. Em LAN, T09 teve RPS médio inferior ao HTTP/2 em T08, embora superior ao T09 da primeira rodada. Em WAN, T12 teve RPS médio maior na segunda rodada, mas sua dispersão entre repetições continua alta. Os resultados variam com o cenário e a carga e não sustentam a afirmação de que HTTP/3 seja sempre mais rápido.

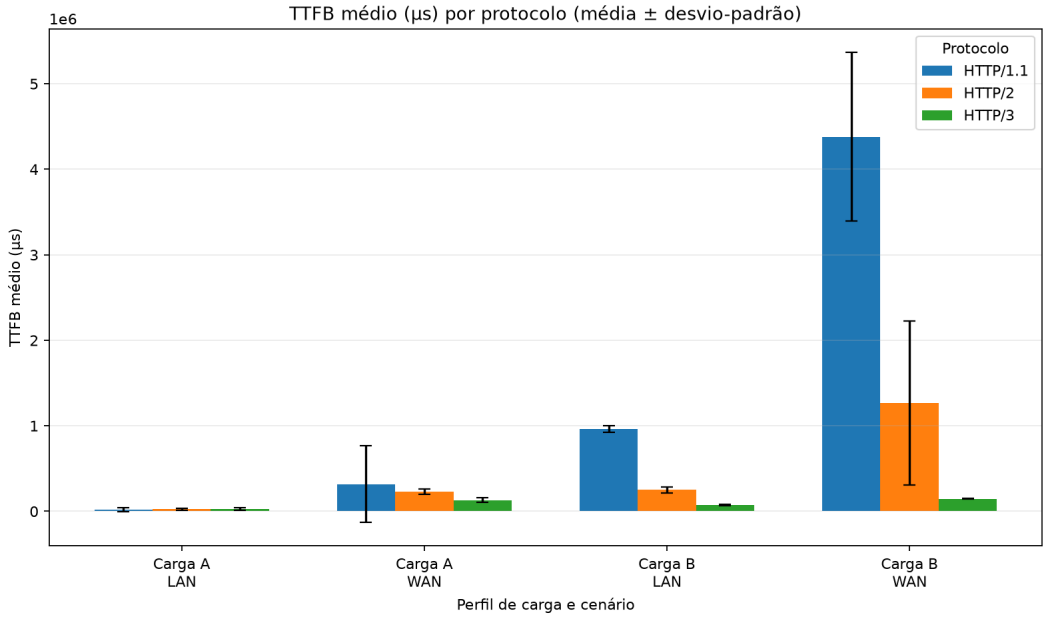


Figura 1: TTFB por protocolo, carga e cenário na segunda rodada. Barras de erro: ± um desvio-padrão entre cinco repetições.

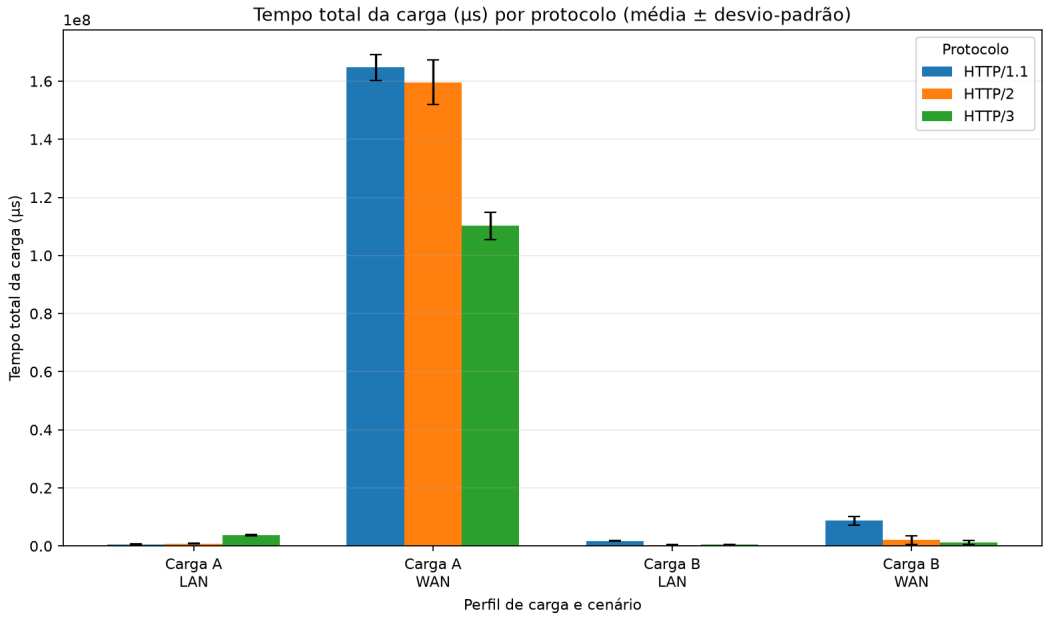


Figura 2: Tempo total da carga por protocolo, carga e cenário na segunda rodada. Barras de erro: ± um desvio-padrão entre cinco repetições.

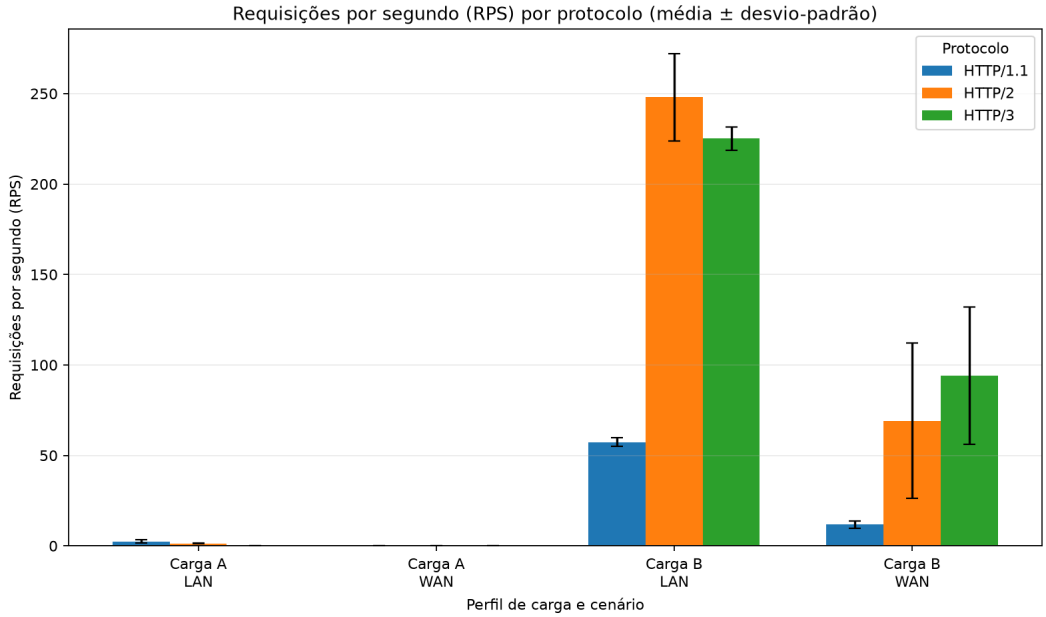


Figura 3: RPS por protocolo, carga e cenário na segunda rodada. Barras de erro: ± um desvio-padrão entre cinco repetições.

As tabelas estatísticas completas, incluindo percentis de latência calculados a partir dos registros individuais, estão nos arquivos summary da rodada 1 e summary da rodada 2.

5 Discussão

5.1 Handshake e TTFB

Os testes de Carga A criam uma conexão nova por requisição, de modo que o TTFB observado inclui o estabelecimento da conexão e o tempo até o primeiro byte do corpo. Na segunda rodada, as médias de TTFB em LAN foram aproximadamente 19,9 ms (T01), 24,8 ms (T02) e 26,2 ms (T03). Em WAN foram 318,9 ms (T04), 228,1 ms (T05) e 131,4 ms (T06). A menor média de TTFB de WAN em T06 é compatível com menor latência inicial para QUIC nesse ensaio, mas não isola o custo do handshake: também inclui processamento no servidor, escalonamento, transporte dos dados e variação entre as cinco observações. Em LAN, HTTP/3 não apresentou o menor TTFB médio nesta rodada. Portanto, os dados não demonstram uma vantagem uniforme de TTFB em todos os cenários.

Os p50/p99 para Carga A têm somente cinco observações individuais por teste, uma por repetição. Esses percentis são descritores empíricos muito instáveis e não devem ser interpretados como estimativas precisas da cauda de latência. Para Carga B, os percentis agregam 500 pedidos, mas os pedidos pertencem a cinco lotes concorrentes e não são 500 observações independentes.

5.2 Objeto grande e transporte

Para um objeto de 50.000.000 bytes, o tempo médio da segunda rodada em LAN foi 0,477 s em T01, 0,771 s em T02 e 3,824 s em T03. Isso corresponde aproximadamente a 105, 65 e 13 MB/s, respectivamente, usando MB decimal e o tempo médio da carga. O resultado de T03 mostra que esta implementação HTTP/3/aioquic foi bem mais lenta que as implementações TCP no cenário LAN de objeto grande. Ele não prova que QUIC como protocolo seja intrinsecamente mais lento: diferenças de implementação, cópias e processamento em espaço de usuário, configuração e limites do host podem contribuir.

Na WAN, os tempos médios foram 164,739 s (T04), 159,564 s (T05) e 110,153 s (T06), ou aproximadamente 0,304, 0,313 e 0,454 MB/s. HTTP/3 teve maior vazão efetiva e menor duração neste conjunto. A configuração injetou 2% de perda na saída dos servidores e 25 ms de atraso em cada sentido. A forte diferença entre LAN e WAN é compatível com o impacto de RTT e perda na recuperação de transporte. É coerente discutir CUBIC para T04/T05 se o kernel Linux de fato usou o algoritmo padrão esperado, mas o experimento não registrou diretamente o algoritmo TCP ativo nem a evolução da janela de congestionamento. Assim, a associação com CUBIC é uma interpretação teórica, não uma variável medida.

Em Carga A há somente uma requisição por amostra; o campo RPS é essencialmente o inverso da duração daquela transferência e não é uma métrica apropriada para comparar vazão de objeto grande. Para essa carga, tempo total e bytes transferidos são mais informativos.

5.3 Objetos pequenos, multiplexação e HoL

Na segunda rodada em LAN, a carga concorrente alcançou cerca de 57 RPS em T07, 248 RPS em T08 e 225 RPS em T09. HTTP/2 superou HTTP/3 em RPS médio neste cenário,

enquanto HTTP/3 teve o menor TTFB de requisição (p50 aproximado de 71,6 ms contra 279,5 ms em HTTP/2). Isso indica que as métricas não apontam um vencedor único: HTTP/3 iniciou as respostas mais rapidamente no conjunto medido, mas o lote HTTP/2 completou mais requisições por segundo. HTTP/1.1 ficou atrás, resultado compatível com a serialização sobre uma conexão limitada a um canal.

Na WAN, T10/T11/T12 registraram aproximadamente 11,8, 69,2 e 94,0 RPS, respectivamente. O TTFB p50 por requisição foi aproximadamente 4,15 s, 0,762 s e 0,149 s. O padrão é compatível com custo de RTT e serialização em HTTP/1.1, com multiplexação em HTTP/2, e com streams independentes de QUIC reduzindo o bloqueio entre streams. Ainda assim, T12 teve desvio-padrão de cerca de 37,9 RPS entre repetições e p99 de duração individual de cerca de 2,12 s, indicando dispersão e eventos de cauda relevantes. A independência de streams não elimina perda, retransmissão ou controle de congestionamento compartilhado pela conexão.

5.4 Variação entre rodadas e limites de inferência

As duas rodadas concordam qualitativamente que HTTP/1.1 tem desempenho inferior na carga concorrente WAN (T10) e que HTTP/3 foi mais rápido que os dois protocolos TCP para o objeto grande WAN (T06). Outros resultados variaram: T08 subiu de 162 para 248 RPS entre rodadas, enquanto T09 passou de 193 para 225 RPS; em T12, HTTP/3 passou de 54 para 94 RPS, com dispersão elevada em ambas as rodadas. Essa variação pode refletir escalonamento, estado do host, operações em segundo plano e aleatoriedade de perdas. Como as rodadas não foram planejadas como um ensaio controlado de repetibilidade, elas são reportadas separadamente e não foram agregadas como se fossem dez repetições equivalentes.

O BBR não foi configurado nem verificado na imagem Caddy usada; portanto, não é possível atribuir os resultados HTTP/3 a BBR. A explicação suportada pelos dados é limitada à implementação de HTTP/3/QUIC executada e à propriedade arquitetural de isolamento entre streams.

6 Limitações e reprodutibilidade

O experimento compara implementações concretas (Nginx, Caddy e aioquic/httpx), não implementações abstratas dos padrões. O cliente aioquic e os servidores Caddy/Nginx não são a mesma pilha de implementação, e o algoritmo de congestionamento usado por QUIC não foi verificado. O `tc netem` é aplicado à saída das interfaces dos contêineres, de modo que tráfego de controle e de aplicação também pode ser afetado. Os 2% são uma probabilidade de perda por pacote na saída dos servidores, não uma taxa constante de perda de bytes. O caminho de contêineres não representa toda a variabilidade da Internet real.

As execuções ocorreram no Docker Desktop para Windows com backend Linux/WSL2, em uma máquina reportada pelo Docker com quatro CPUs e aproximadamente 3,8 GiB disponíveis. A versão do cliente Docker/Compose informada durante a execução foi 29.5.2/5.1.4. As imagens Nginx e Python usam tags móveis (`alpine` e `3.12-slim`) e as dependências Python têm faixas de versão, sem lockfile; isso limita a reprodução binária exata. O identificador de imagem Caddy no Compose é `2.7-alpine`. Para reprodução

futura rigorosa, devem ser registrados os digests das imagens e as versões efetivamente resolvidas dos pacotes.

Para reproduzir, em Linux com Docker Compose, OpenSSL e permissões para executar Docker (ou Docker Desktop com Git Bash no Windows):

```
chmod +x run_experiments.sh scripts/*.sh
REPETITIONS=5 ./run_experiments.sh
```

O runner salva os dados brutos em JSON e CSV e os gráficos e a tabela consolidada no diretório de resultados identificado pelo horário UTC da execução. A automação encerra os contêineres e remove `tc qdisc` também em caso de falha. Os artefatos gerados devem ser preservados junto com as anotações do ambiente experimental.

7 Conclusão

Nas condições testadas, os resultados não mostram um protocolo vencedor para todas as cargas. HTTP/3 apresentou o menor tempo médio para transferir o objeto grande na WAN (T06, cerca de 110 s, contra 160–165 s em TCP) e o maior RPS médio na carga concorrente WAN da segunda rodada (T12, cerca de 94 RPS). Em contrapartida, HTTP/3 teve o maior tempo para o objeto grande em LAN (T03, cerca de 3,82 s), e HTTP/2 alcançou maior RPS que HTTP/3 na carga concorrente LAN da segunda rodada (T08 versus T09). HTTP/1.1 teve o menor RPS nos testes de objetos pequenos, especialmente na WAN.

Esses resultados são compatíveis com benefícios de multiplexação e isolamento de streams em algumas condições, mas também evidenciam o custo de implementação e a variabilidade. Cinco repetições por teste, sobretudo cinco observações para latência da carga A, não bastam para caracterizar com precisão caudas raras ou provar significância estatística. A explicação baseada em TCP CUBIC é teoricamente pertinente, mas o algoritmo e a janela ativa não foram medidos; da mesma forma, não se comprovou o uso de BBR em QUIC. Portanto, as conclusões se restringem às versões e ao ambiente documentados e não devem ser extrapoladas para todos os servidores, clientes ou redes reais.

Referências

[1] TANENBAUM, Andrew S.; WETHERALL, David J. *Redes de Computadores*. 5. ed. São Paulo: Pearson Prentice Hall, 2011. Seções 6.5.11–6.6.2.

[2] FIELDING, R. et al. *HTTP Semantics*. RFC 9110, 2022. https://www.rfc-editor.org/rfc/rfc9110

[3] THOMSON, M.; TURNER, S. *Using TLS to Secure QUIC*. RFC 9001, 2021. https://www.rfc-editor.org/rfc/rfc9001

[4] BISHOP, M. *HTTP/3*. RFC 9114, 2022. https://www.rfc-editor.org/rfc/rfc9114

[5] IYENGAR, J.; THOMSON, M. *QUIC: A UDP-Based Multiplexed and Secure Transport*. RFC 9000, 2021. https://www.rfc-editor.org/rfc/rfc9000